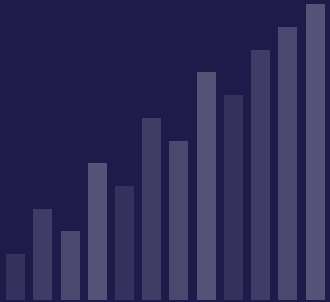
AULA 19 · BLOCO 3: DICIONÁRIOS: HASH E ÁRVORES

Tabelas hash com encadeamento

Cormen et al., *Algoritmos*: seções 11.1 e 11.2



TEORIA

Roteiro da aula

Ao final, você será capaz de

- Explicar endereçamento direto e por que ele não escala
- Resolver colisões por encadeamento
- Analisar a busca em função do fator de carga $\alpha = n/m$
- Medir α e $1 + \alpha/2$ elementos examinados por busca

Teoria

Dicionários, endereçamento direto, hash, colisões e o teorema 11.1/11.2

Prática em C

Frequência de palavras com uma tabela hash em C

Experimento

Custo de busca com e sem sucesso para α de 0,25 a 4

Conexões

Bancos de dados, compiladores, redes e cache distribuído



Teoria

- Cormen et al., seções 11.1 e 11.2
- Dicionários e endereçamento direto
- Funções hash e colisões
- Encadeamento
- Análise: o fator de carga

TEORIA

Dicionários e endereçamento direto

- **Dicionário**: INSERT, SEARCH, DELETE.
- Se as chaves vêm de um universo pequeno $U = \{0, \ldots, m-1\}$, use um vetor: $T[k]$ guarda a chave k.
- Tudo em $O(1)$ no pior caso.
- Problema: o universo costuma ser enorme (CPFs, URLs, palavras) e o conjunto K de chaves usadas, pequeno. Memória $|U|$ é inviável.

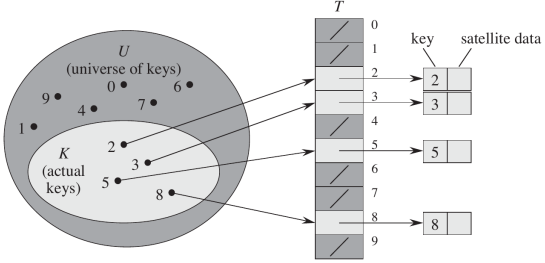


Figura 11.1 de Cormen et al. (2009) — tabela de endereçamento direto: a chave é o próprio índice.

TEORIA

Funções hash e colisões

- Uma **função hash** $h : U \to \{0, \ldots, m-1\}$ diz onde guardar cada chave.
- Memória $\Theta(|K|)$ em vez de $\Theta(|U|)$.
- Como $|U| > m$, **colisões** são inevitáveis (princípio da casa dos pombos).
- Duas soluções: encadeamento (hoje) e endereçamento aberto (aula 21).

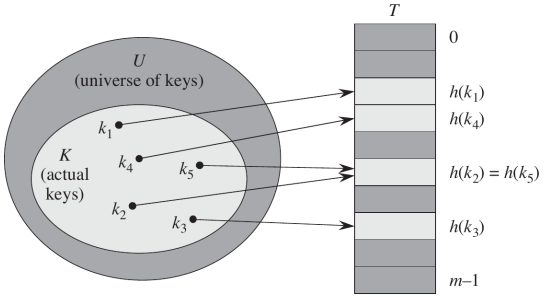


Figura 11.2 de Cormen et al. (2009) — h leva o universo U para m posições; k_2 e k_5 colidem.

TEORIA

Encadeamento

- INSERT(T, x): insere na cabeça da lista $T[h(x.chave)]$: $O(1)$.
- SEARCH(T, k): percorre a lista $T[h(k)]$.
- DELETE(T, x): $O(1)$ com listas duplamente ligadas.
- Pior caso: todas as chaves na mesma lista, $\Theta(n)$.

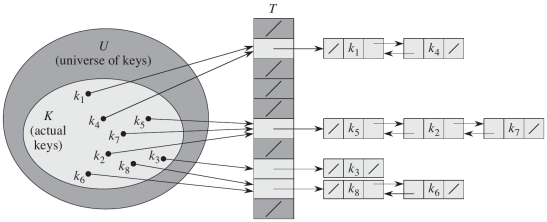


Figura 11.3 de Cormen et al. (2009) — cada posição guarda uma lista com as chaves que caíram nela.

TEORIA

Análise: o fator de carga

Hash uniforme simples: cada chave cai em qualquer das m posições com a mesma probabilidade, independentemente das outras. Seja $\alpha = n/m$ o **fator de carga**.

- **Teorema 11.1** (sem sucesso): a busca examina em média α elementos; tempo $\Theta(1+\alpha)$.
- **Teorema 11.2** (com sucesso): examina em média $1 + \frac{\alpha}{2} - \frac{\alpha}{2n}$ elementos.
- Se m cresce junto com n ($n = O(m)$), então $\alpha = O(1)$ e **todas as operações são $O(1)$ em média**.

> Na prática: dobre m (e reinsira tudo) quando α passar de um limite, como no vetor dinâmico da aula 16: custo amortizado $O(1)$.

Prática em C

- Hash de strings: polinômio em base 31, resto por $m = 101$ (primo)
- Listas na cabeça; busca antes de inserir para contar repetições
- Ao fim: palavras, posições usadas e a maior lista

PRÁTICA EM C

Frequência de palavras com hash (1/4)

```c
#include <stdio.h>
#include <stdlib.h>
#include <string.h>

#define M 101                                   // número de posições (primo)

typedef struct No { char *palavra; int cont; struct No *prox; } No;
No *T[M];                                       // T[i] é a lista da posição i

/* Polinômio em base 31 com resto por M: método da divisão aplicado à string. */
unsigned h(const char *s) {
    unsigned long v = 0;
    for (; *s; s++) v = (v * 31 + (unsigned char)*s) % M;
    return v;
}
```

PRÁTICA EM C

Frequência de palavras com hash (2/4)

```
16
17 No *busca(const char *s) {                    // CHAINED-HASH-SEARCH: percorre T[h(s)]
18     for (No *x = T[h(s)]; x; x = x->prox)
19         if (strcmp(x->palavra, s) == 0) return x;
20     return NULL;
21 }
```

PRÁTICA EM C

Frequência de palavras com hash (3/4)

```c
void insere(const char *s) {                    // CHAINED-HASH-INSERT na cabeça: O(1)
    No *x = busca(s);
    if (x) { x->cont++; return; }               // já existe: só conta
    x = malloc(sizeof(No));
    x->palavra = malloc(strlen(s) + 1);
    strcpy(x->palavra, s);
    x->cont = 1;
    x->prox = T[h(s)];
    T[h(s)] = x;
}

int main(void) {
    char p[100];
    int n = 0;
    while (scanf("%99s", p) == 1) { insere(p); n++; }
```

PRÁTICA EM C

Frequência de palavras com hash (4/4)

```
38      int usadas = 0, maior = 0;
39      for (int i = 0; i < M; i++) {
40          int tam = 0;
41          for (No *x = T[i]; x; x = x->prox) {
42              printf("%s: %d\n", x->palavra, x->cont);
43              tam++;
44          }
45          if (tam) usadas++;
46          if (tam > maior) maior = tam;
47      }
48      printf("%d palavras, %d posições usadas de %d, maior lista: %d\n",
49             n, usadas, M, maior);
50      for (int i = 0; i < M; i++)
51          while (T[i]) { No *x = T[i]; T[i] = x->prox; free(x->palavra); free(x); }
52      return 0;
53  }
```



Experimento

- Hipótese: α (sem sucesso) e $1 + \alpha/2$ (com sucesso)
- $m = 65.536$, α de 0,25 a 4
- Chaves aleatórias de 32 bits (hash uniforme)

EXPERIMENTO

O fator de carga decide

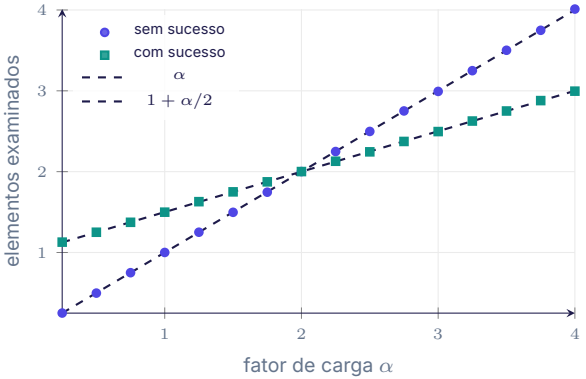
Hipótese. Com hash uniforme simples, uma busca **sem sucesso** percorre uma lista inteira: em média α elementos. Uma busca **com sucesso** pela i-ésima chave inserida examina ela mesma mais as inseridas depois na mesma lista: em média $1 + \alpha/2$.

Método

1. $m = 2^{16}$ posições, $n = \alpha m$ chaves aleatórias
2. $\alpha = 0{,}25, 0{,}5, \ldots, 4$
3. Com sucesso: busca de todas as n chaves
4. Sem sucesso: 200.000 chaves sorteadas

EXPERIMENTO

Elementos examinados por busca



$alfa$	medido	razão
0,250	0,251	1,004
1,000	1,000	1,000
1,750	1,746	0,998
2,500	2,498	0,999
3,250	3,249	1,000
4,000	4,011	1,003

razão = medido ÷ α

✔ desvio máx. 0,3%

As duas retas se cruzam em $\alpha = 2$: acima disso, procurar algo que não existe custa mais que achar.

EXPERIMENTO

O que o experimento mostrou

Os teoremas 11.1 e 11.2 se confirmam com desvio menor que 1%: α elementos sem sucesso, $1 + \alpha/2$ com sucesso. O custo depende de α, **não de** n: com α fixo, uma tabela com um bilhão de chaves busca tão rápido quanto uma com mil.

Reproduza: `gcc -O2 aula19_experimento.c -o exp -lm && ./exp`



Conexões

- Bancos de dados
- Compiladores e linguagens
- Cache distribuído
- Redes

CONEXÕES

Onde isso aparece na computação

Bancos de dados

Índices hash respondem `WHERE id = ?` em $O(1)$; o *hash join* monta uma tabela hash com a menor relação e varre a maior.

Compiladores e linguagens

A tabela de símbolos guarda identificadores numa tabela hash; dicionários do Python, objetos do JavaScript e `HashMap` do Java também.

Cache distribuído

Memcached e Redis distribuem chaves entre servidores com hash; o *hashing consistente* minimiza as chaves movidas quando um servidor entra ou sai.

Redes

Switches mantêm a tabela de endereços MAC em hash; roteadores e firewalls classificam fluxos (5-tupla) por hash para decidir em nanossegundos.

PARA CASA

Para casa

Exercícios

1. (11.1-1) Como achar o máximo numa tabela de endereçamento direto? Qual o custo?
2. (11.2-2) Insira 5, 28, 19, 15, 20, 33, 12, 17, 10 com $h(k) = k \bmod 9$ e encadeamento.
3. (11.2-3) E se as listas forem mantidas ordenadas? O que muda em cada operação?
4. Rode `aula19_hash_encadeamento.c` com um livro inteiro (Domínio Público) e analise a maior lista.
5. Implemente o redimensionamento: dobre m quando $\alpha > 1$ e meça o custo amortizado.

Leitura
Cormen et al., seções 11.1 e 11.2.

Código
josedihego.net/estruturas