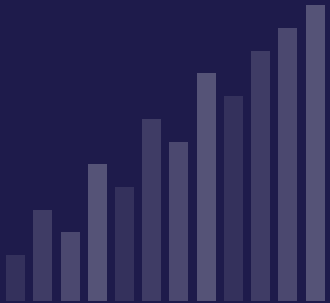
AULA 35 · BLOCO 4: GRAFOS E TÉCNICAS DE PROJETO

Casamento de cadeias: o algoritmo de Knuth-Morris-Pratt

Cormen et al., *Algoritmos*: seções 32.1 e 32.4



TEORIA

Roteiro da aula

Ao final, você será capaz de

- Definir o problema de casamento de cadeias e o algoritmo ingênuo
- Calcular a função de prefixo π de um padrão
- Executar o KMP e mostrar que ele é $\Theta(n + m)$
- Medir o pior caso do ingênuo contra o KMP

Teoria

O problema, o ingênuo, a função de prefixo e o KMP

Prática em C

KMP em C

Experimento

Texto a^n e padrão $a^{99}b$: $(n - m + 1)m$ contra $\leq 3n$

Conexões

Buscadores, segurança, bioinformática e editores



Teoria

- Cormen et al., seções 32.1 e 32.4
- O problema
- Os algoritmos do capítulo
- A função de prefixo
- KMP

TEORIA

O problema

Dado um texto $T[1..n]$ e um padrão $P[1..m]$, achar todos os deslocamentos s com $T[s+1..s+m] = P$. **Ingênuo:** testa cada um dos $n - m + 1$ deslocamentos comparando até m caracteres: $O((n-m+1)m)$. Pior caso: $T = a^n$, $P = a^{m-1}b$.

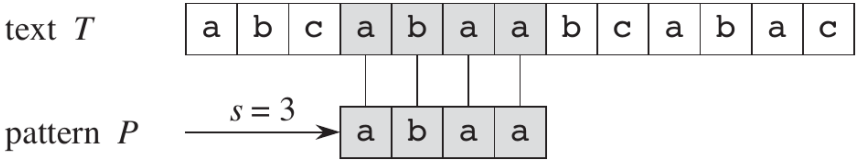


Figura 32.1 de Cormen et al. (2009) — o padrão $P = \text{abaa}$ ocorre no texto T com deslocamento $s = 3$.

TEORIA

Os algoritmos do capítulo

- **Rabin-Karp**: compara hashes das janelas (aula 20); rápido em média, $O((n-m+1)m)$ no pior caso.
- **Autômato finito**: $\Theta(n)$ para casar, mas pré-processamento $O(m|\Sigma|)$.
- **KMP**: $\Theta(m)$ de pré-processamento e $\Theta(n)$ para casar, sem depender do alfabeto.

Algorithm	Preprocessing time	Matching time
Naive	0	$O((n-m+1)m)$
Rabin-Karp	$\Theta(m)$	$O((n-m+1)m)$
Finite automaton	$O(m\,\lvert\Sigma\rvert)$	$\Theta(n)$
Knuth-Morris-Pratt	$\Theta(m)$	$\Theta(n)$

Figura 32.2 de Cormen et al. (2009) — tempos de pré-processamento e de casamento.

TEORIA

A função de prefixo

$\pi[q]$ = tamanho do maior prefixo **próprio** de P_q que também é **sufixo** de P_q.

- Depois de casar q caracteres e falhar, não é preciso voltar no texto: o padrão continua da posição $\pi[q]$.
- Os caracteres do texto nunca são relidos para trás.
- Calcular π é o KMP do padrão contra ele mesmo: $\Theta(m)$.

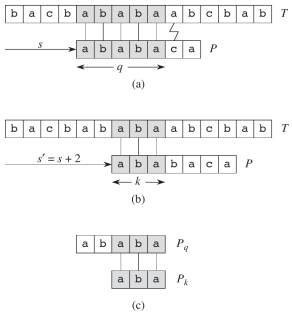


Figura 32.10 de Cormen et al. (2009) — (a) $q = 5$ caracteres casaram e o próximo falha; (b) desloca-se P para o maior prefixo que é também sufixo; (c) $\pi[5] = 3$.

TEORIA

KMP

Análise amortizada: q aumenta no máximo n vezes (uma por caractere); cada volta do **enquanto** diminui q. Então o **enquanto** roda no máximo n vezes no total.

Casamento: $\Theta(n)$. Total com o pré-processamento: $\Theta(n+m)$.

KMP-Matcher(T, P)

```
1  π ← Compute-Prefix-Function(P)
2  q ← 0                                  // caracteres casados
3  para i ← 1 até n faça
4      enquanto q > 0 e P[q + 1] ≠ T[i] faça
5          q ← π[q]
6      se P[q + 1] = T[i] então
7          q ← q + 1
8      se q = m então
9          imprima "ocorrência com deslocamento" i − m
10         q ← π[q]
```

Prática em C

- Função de prefixo com índices de 0
- KMP que relata todas as ocorrências (inclusive sobrepostas)
- Testes com o exemplo da Figura 32.10

PRÁTICA EM C

Knuth-Morris-Pratt em C (1/2)

```c
#include <stdio.h>
#include <string.h>

/* pi[q] = tamanho do maior prefixo próprio de P[0..q] que também é sufixo dele.
   Quando um caractere não casa, voltamos para pi[q-1] em vez de recomeçar. */
void prefixo(const char *P, int m, int pi[]) {   // COMPUTE-PREFIX-FUNCTION: θ(m)
    pi[0] = 0;
    for (int q = 1, k = 0; q < m; q++) {
        while (k > 0 && P[k] != P[q]) k = pi[k - 1];
        if (P[k] == P[q]) k++;
        pi[q] = k;
    }
}

int main(void) {
```

PRÁTICA EM C

Knuth-Morris-Pratt em C (2/2)

```
0
    char T[1001], P[101];
    if (scanf("%1000s %100s", T, P) != 2) return 1;
    int n = strlen(T), m = strlen(P), pi[101], achou = 0;
    prefixo(P, m, pi);
    for (int i = 0, q = 0; i < n; i++) {        // KMP-MATCHER: 0(n)
        while (q > 0 && P[q] != T[i]) q = pi[q - 1];
        if (P[q] == T[i]) q++;
        if (q == m) {                           // casou P inteiro terminando em i
            printf("ocorrência no deslocamento %d\n", i - m + 1);
            achou = 1;
            q = pi[q - 1];                      // procura a próxima
        }
    }
    if (!achou) printf("nenhuma ocorrência\n");
    return 0;
```



Experimento

- Texto a^n, padrão $a^{99}b$ ($m = 100$)
- Ingênuo: exatamente $(n - m + 1)m$
- KMP: no máximo $3n$ (contando o teste que encerra cada laço)

EXPERIMENTO

O pior caso do ingênuo

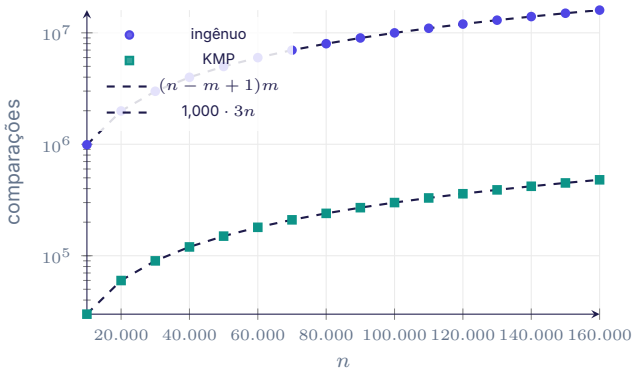
Hipótese. No ingênuo, cada deslocamento casa 99 caracteres antes de falhar no último: exatamente $(n - 99) \cdot 100$ comparações. No KMP, cada caractere do texto custa no máximo uma comparação no **se**, uma que encerra o **enquanto** e, amortizadas, as voltas do **enquanto**: no máximo $3n$.

Método

1. n de 10.000 a 160.000
2. Contador em toda comparação entre caracteres
3. Mesma entrada para os dois algoritmos
4. Padrão ausente: nenhuma ocorrência

EXPERIMENTO

Comparações: ingênuo contra KMP



n	medido	razão
10.000	990.100	1,000
40.000	3.990.100	1,000
70.000	6.990.100	1,000
100.000	9.990.100	1,000
130.000	12.990.100	1,000
160.000	15.990.100	1,000

razão = medido $\div$ $(n - m + 1)m$

✓ desvio máx. 0,0%

Para $n = 160.000$: 16 milhões de comparações no ingênuo, 480 mil no KMP: 33 vezes menos, e a razão cresce com m.

EXPERIMENTO

O que o experimento mostrou

O ingênuo faz exatamente $(n - m + 1)m$ comparações no pior caso; o KMP fica abaixo de $3n$, **independente de** m. A função de prefixo é uma pequena tabela que evita reler o texto: mais uma vez, pré-processar troca memória por tempo.

Reproduza: `gcc -O2 aula35_experimento.c -o exp -lm && ./exp`



Conexões

- Busca em texto
- Segurança
- Bioinformática
- Compiladores

CONEXÕES

Onde isso aparece na computação

Busca em texto

`grep`, o “localizar dos editores e navegadores e as bibliotecas de strings usam KMP, Boyer-Moore ou variações para buscar em gigabytes.

Segurança

Antivírus e sistemas de detecção de intrusão (Snort, Suricata) procuram milhares de assinaturas ao mesmo tempo com Aho-Corasick, a generalização do KMP.

Bioinformática

Localizar motivos em DNA, sítios de restrição e sequências repetidas: casamento de cadeias sobre o alfabeto $\{A, C, G, T\}$.

Compiladores

Analisadores léxicos reconhecem palavras-chave e tokens com autômatos finitos, o mesmo modelo da seção 32.3.

PARA CASA

Para casa

Exercícios

1. (32.1-2) Se todos os caracteres de P são diferentes, acelere o ingênuo para $O(n)$.
2. (32.4-1) Calcule a função de prefixo de ababbabbabbababbabb.
3. (32.4-7) Decida se T é uma rotação cíclica de T' em tempo linear.
4. (32.2-1) Simule o Rabin-Karp com módulo 11 em $T = 3141592653589793$ e $P = 26$: quantos alarmes falsos?
5. Meça o experimento com texto aleatório em português. O ingênuo ainda perde? Por quê?

Leitura
Cormen et al., seções 32.1, 32.2 e 32.4.

Código
josedihego.net/estruturas